

In [1]:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import re
import warnings
warnings.filterwarnings('ignore')
plt.rcParams['font.sans-serif']=['Microsoft YaHei']
%matplotlib inline
```

读取文件并合并

In [2]:

```
city_list = '北京,上海,广州,深圳'.split(',')
```

In [3]:

```
path_list = [f'./{i}历史天气.xlsx' for i in city_list]
df_list = []
for path in path_list :
    df = pd.read_excel(path)
    df['地区']= path[2:4]
    df_list.append(df)
```

In [4]:

```
df_p = pd.concat(df_list)
```

一、数据清洗

In [5]:

```
df_p['空气质量等级'] = df_p['空气质量指数'].map(lambda i: re.compile(r'\s(\w{1,15})')
df_p['空气质量指数'] = df_p['空气质量指数'].map(lambda i: re.compile(r'(\d*)\s').fi
```

In [6]:

```
df_p.head()
```

Out[6]:

	日期	最高温	最低温	天气	风力风向	空气质量指数	地区	空气质量等级
0	2021-05-01 周六	20°	7°	晴	北风3级	33	北京	优
1	2021-05-02 周日	21°	13°	阴~晴	南风3级	39	北京	优
2	2021-05-03 周一	24°	13°	晴~多云	西南风微风	63	北京	良
3	2021-05-04 周二	23°	10°	多云	西北风3级	53	北京	良
4	2021-05-05 周三	27°	16°	晴	西南风微风	70	北京	良

In [7]:

```
df_p.loc[:, '日期'] = df_p['日期'].str[0:10]
df_p['风向'] = df_p['风力风向'].map(lambda i: i[:-2])
df_p.loc[:, '风力等级'] = df_p['风力风向'].map(lambda i: i[-2])
df_p.loc[:, '风力等级'] = df_p.loc[:, '风力等级'].map(lambda i: 0 if i == '微' else
df_p.loc[:, '最高温'] = df_p['最高温'].str.replace('°', '').astype('int32')
df_p.loc[:, '最低温'] = df_p['最低温'].str.replace('°', '').astype('int32')
del df_p['风力风向']
```

In [8]:

```
df_p['日期'] = pd.to_datetime(df_p['日期'])
df_p.set_index('日期', drop = False, inplace = True)
df_p.sort_index(inplace = True)
```

In [9]:

```
df = df_p.loc['2020-01-01': '2020-12-31']
```

In [10]:

```
pd.unique(df['空气质量等级'])
```

Out[10]:

```
array(['良', '优', '轻度', '中度', '重度'], dtype=object)
```

In [11]:

```
def air_s(i):
    if i in ['中度', '轻度', '重度', '严重']:
        return f'{i}污染'
    else:
        return i
df.loc[:, '空气质量等级'] = df['空气质量等级'].map(air_s)
```

```
In [12]:
pd.unique(df['空气质量等级'])

Out[12]:
array(['良', '优', '轻度污染', '中度污染', '重度污染'], dtype=object)
```

清洗完成，对必要字段进行了拆分，替换

二、对四个城市每月平均温度变化进行分析

```
In [13]:
df.head()

Out[13]:
```

	日期	最高温	最低温	天气	空气质量指数	地区	空气质量等级	风向	风力等级
日期									
2020-01-01	2020-01-01	0	-9	晴	53	北京	良	东北风	1
2020-01-01	2020-01-01	18	16	阴~多云	52	深圳	良	东南风	2
2020-01-01	2020-01-01	9	7	晴~小雨	27	上海	优	东南风	2
2020-01-01	2020-01-01	20	13	多云~晴	60	广州	良	东北风	2
2020-01-02	2020-01-02	19	16	阴~多云	50	深圳	优	东南风	1


```
In [14]:
month_t = df.groupby([df.index.month, '地区'])['最高温'].mean().unstack()
```

In [15]:

```
month_t.plot(figsize=(10, 5))  
plt.title('“北上广深”2020气温变换折线图')  
plt.xlabel('月')  
plt.ylabel('温度℃')
```

Out[15]:

Text(0, 0.5, '温度℃')



三、分析四个城市一年中，每天的温度分情况

In [16]:

```
df.head()
```

Out[16]:

	日期	最高温	最低温	天气	空气质量指数	地区	空气质量等级	风向	风力等级
日期									
2020-01-01	2020-01-01	0	-9	晴	53	北京	良	东北风	1
2020-01-01	2020-01-01	18	16	阴~多云	52	深圳	良	东南风	2
2020-01-01	2020-01-01	9	7	晴~小雨	27	上海	优	东南风	2
2020-01-01	2020-01-01	20	13	多云~晴	60	广州	良	东北风	2
2020-01-02	2020-01-02	19	16	阴~多云	50	深圳	优	东南风	1

In [17]:

```
df_plot = df[['最高温', '地区']].set_index('地区', append = True).unstack().reset_
```

In [18]:

```
columns_plot_p = df_plot.columns.values.tolist()
columns_plot = []
for i in columns_plot_p:
    a,b = i
    columns_plot.append(b)
```

In [19]:


```
data_p = list(df_plot.to_dict().values())
all_data = []
for i in data_p:
    values = list(i.values())
    all_data.append(values)
```

In [20]:

```
fig, axs = plt.subplots(nrows=1, ncols=2, figsize=(12, 4))
axs[0].violinplot(all_data, showmeans=False, showmedians=True)
axs[0].set_title('温度分布小提琴图 (天)')
axs[1].boxplot(all_data)
axs[1].set_title('分度分布箱线图 (天)')
for ax in axs:
    ax.yaxis.grid(True)
    ax.set_xticks([y + 1 for y in range(len(all_data))])
    ax.set_ylabel('温度℃')
plt.setp(axs, xticks=[y + 1 for y in range(len(all_data))],
          xticklabels= columns_plot)
```

Out[20]:

```
[<matplotlib.axis.XTick at 0x2604665aaf0>,
 <matplotlib.axis.XTick at 0x2604665aee0>,
 <matplotlib.axis.XTick at 0x26046643280>,
 <matplotlib.axis.XTick at 0x26047729c10>,
 Text(1, 0, '上海'),
 Text(2, 0, '北京'),
 Text(3, 0, '广州'),
 Text(4, 0, '深圳'),
 <matplotlib.axis.XTick at 0x2604768b5e0>,
 <matplotlib.axis.XTick at 0x2604768b5b0>,
 <matplotlib.axis.XTick at 0x260476a3a30>,
 <matplotlib.axis.XTick at 0x260477329d0>,
 Text(1, 0, '上海'),
 Text(2, 0, '北京'),
 Text(3, 0, '广州'),
 Text(4, 0, '深圳')]
```



四、分析四个城市一年中空气质量的分布情况

```
In [21]:
df.head()
```

Out[21]:

	日期	最高温	最低温	天气	空气质量指数	地区	空气质量等级	风向	风力等级
日期									
2020-01-01	2020-01-01	0	-9	晴	53	北京	良	东北风	1
2020-01-01	2020-01-01	18	16	阴~多云	52	深圳	良	东南风	2
2020-01-01	2020-01-01	9	7	晴~小雨	27	上海	优	东南风	2
2020-01-01	2020-01-01	20	13	多云~晴	60	广州	良	东北风	2
2020-01-02	2020-01-02	19	16	阴~多云	50	深圳	优	东南风	1

```
In [22]:
month_a = df.groupby(['地区','空气质量等级'])['空气质量等级'].count()
month_a = month_a.unstack(fill_value = 0,level = 0)
```

```
In [23]:
from pandas.api.types import CategoricalDtype
act_size_order = CategoricalDtype(['优','良','轻度污染','中度污染','重度污染'],order
month_a = month_a.reset_index()
month_a['空气质量等级'] = month_a['空气质量等级'].astype(act_size_order)
month_a = month_a.sort_values('空气质量等级').set_index('空气质量等级')
month_a
```

Out[23]:

地区	上海	北京	广州	深圳
空气质量等级				
优	222	144	237	292
良	121	167	116	74
轻度污染	18	39	12	0
中度污染	5	10	1	0
重度污染	0	6	0	0

```
In [24]:
dic_keys = month_a.index.values
columns_names = month_a.columns.values.tolist()
```

In [25]:

```
month_b = month_a.stack().to_dict().values()
values = np.array(list(month_b)).reshape(5,4).tolist()
```

In [26]:


```
month_c = df.groupby(['地区', '空气质量等级'])['空气质量等级'].count()
month_c = month_c.unstack(fill_value = 0)
month_c = month_c[['优', '良', '轻度污染', '中度污染', '重度污染']]
```

In [27]:

```
month_c.plot(kind='bar', grid = True, colormap='Blues_r', stacked=True, figsize=(10, 10))
plt.table(cellText = values,
          cellLoc='center',
          cellColours = None,
          rowLabels = dic_keys,
          rowColours = plt.cm.BuPu(np.linspace(0, 0.5, 5))[:, :-1], # BuPu可替换成
          colLabels = columns_names,
          colColours = plt.cm.Redd(np.linspace(0, 0.5, 5))[:, :-1],
          rowLoc='right',
          loc='bottom')
plt.xticks([])
plt.xlabel('')
```

Out[27]:

Text(0.5, 0, '')



五、分析污染天气在季节上的分布规律

In [28]:

```
df.head()
```

Out[28]:

	日期	最高温	最低温	天气	空气质量指数	地区	空气质量等级	风向	风力等级
日期									
2020-01-01	2020-01-01	0	-9	晴	53	北京	良	东北风	1
2020-01-01	2020-01-01	18	16	阴~多云	52	深圳	良	东南风	2
2020-01-01	2020-01-01	9	7	晴~小雨	27	上海	优	东南风	2
2020-01-01	2020-01-01	20	13	多云~晴	60	广州	良	东北风	2
2020-01-02	2020-01-02	19	16	阴~多云	50	深圳	优	东南风	1

In [29]:

```
df_p = df[['空气质量等级', '地区']].copy()
df_p['count'] = 1
```

In [30]:

```
df_p=df_p.groupby(by = [df_p.index.quarter, '地区', '空气质量等级'])['count'].count()
```

In [31]:


```
df_u = df_p.unstack(fill_value=0, level = -1)
df_u = df_u.reset_index()
df_u = df_u[['日期', '地区', '轻度污染', '中度污染', '重度污染']]
df_u['污染天数'] = df_u['轻度污染'] + df_u['中度污染'] + df_u['重度污染']
df_u = df_u[['日期', '地区', '污染天数']]
```

In [32]:

```
df_u = df_u.set_index(['日期', '地区']).unstack().reset_index().set_index('日期')
```

In [33]:

```
plt.figure(figsize = (10,5))
plt.plot(df_u[('污染天数','上海')],label='上海')
plt.plot(df_u[('污染天数','北京')],label='北京')
plt.plot(df_u[('污染天数','广州')],label='广州')
plt.plot(df_u[('污染天数','深圳')],label='深圳')
plt.title('“北上广深”2020污染天气——变化图（季度）')
plt.xticks(range(1,5))
plt.xlabel('季度')
plt.ylabel('天')
plt.legend()
for a,b in zip(range(1,5),list(df_u[('污染天数','上海')])):
    plt.text(a,b,b, ha='center', va='bottom', fontsize=10)
for a,b in zip(range(1,5),list(df_u[('污染天数','北京')])):
    plt.text(a,b,b, ha='center', va='bottom', fontsize=10)
for a,b in zip(range(1,5),list(df_u[('污染天数','广州')])):
    plt.text(a,b,b, ha='center', va='bottom', fontsize=10)
for a,b in zip(range(1,5),list(df_u[('污染天数','深圳')])):
    plt.text(a,b,b, ha='center', va='bottom', fontsize=10)
```



六、探寻“空气质量”的影响因素

```
In [34]:
df.head()
```

Out[34]:

	日期	最高温	最低温	天气	空气质量指数	地区	空气质量等级	风向	风力等级
日期									
2020-01-01	2020-01-01	0	-9	晴	53	北京	良	东北风	1
2020-01-01	2020-01-01	18	16	阴~多云	52	深圳	良	东南风	2
2020-01-01	2020-01-01	9	7	晴~小雨	27	上海	优	东南风	2
2020-01-01	2020-01-01	20	13	多云~晴	60	广州	良	东北风	2
2020-01-02	2020-01-02	19	16	阴~多云	50	深圳	优	东南风	1

```
In [35]:
df_p = df.copy()
df_p.loc[:, '温差'] = df_p['最高温']-df_p['最低温']
```

```
In [36]:
df_p.corr().loc['空气质量指数',:]
```

Out[36]:

```
最高温      -0.163287
最低温      -0.256182
空气质量指数    1.000000
风力等级     -0.332844
温差         0.287805
Name: 空气质量指数, dtype: float64
```

空气质量影响因素分析结果

- 空气质量指数和风力等级相关性最强，为负相关，即风力越大，空气质量指数越低，空气质量越好
- 空气质量与温差和最低温相的关性也较强，温差越大时，空气质量可能越差，最低温越低时，空气质量可能越差

七、对北京差天气的原因分析

In [37]:

```
df_p.groupby(by = '地区')['风力等级'].mean()
```

Out[37]:

```
地区
上海      2.524590
北京      2.038251
广州      2.565574
深圳      2.565574
Name: 风力等级, dtype: float64
```

In [38]:

```
df_p.groupby(by = '地区')['最低温'].mean()
```

Out[38]:

```
地区
上海      15.426230
北京       8.262295
广州      20.366120
深圳      21.385246
Name: 最低温, dtype: float64
```

In [39]:

```
df_p.groupby(by = '地区')['温差'].mean()
```

Out[39]:

```
地区
上海       5.811475
北京      10.453552
广州       6.778689
深圳       5.557377
Name: 温差, dtype: float64
```

北京空气质量较差的原因分析结果：

- 虽然和空气质量相关性最高的是风力等级，但不是造成北京空气质量较差的主要原因
- 北京的空气质量较差是因为北京的最低温度和温差比上海、广州、深圳都要大很多

八、天气监控仪表板

北上广深-2020天气分析



数据通过爬虫获取

- 天气网站: <http://tianqi.2345.com/>

In []: